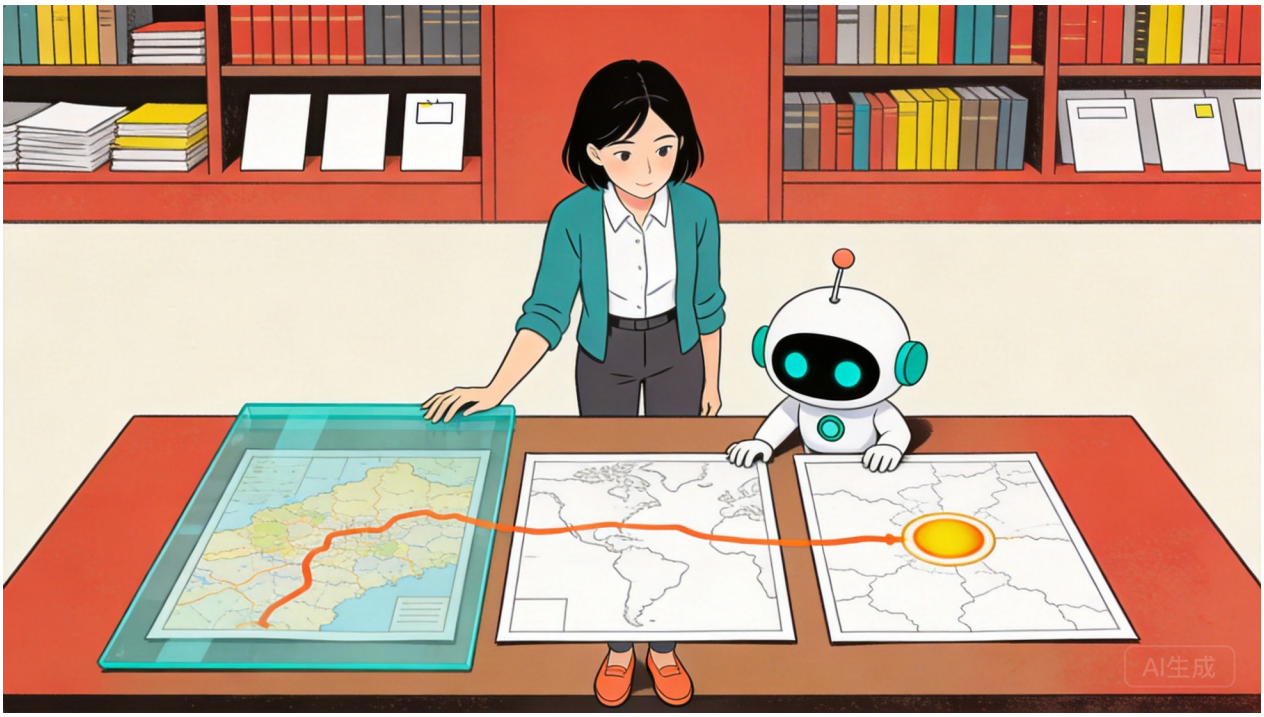
知识库为什么会越用越偏？AI Agent 的知识漂移问题

“通过 ASKS 智能知识系统看 AI Agent”系列第 2 篇

本文通过与 ASKS 系统交互完成。



一次小偏差，如何让知识地图越画越远

想象一座图书馆。

一本书昨天已经入库，今天又被送来一次。管理员没有认出它，给它办了第二张书卡，放上另一个书架，还重新登记了作者、主题和相关读物。

书没有变，图书馆对它的认识却变成了“两本书”。

这不是虚构的场景。ASKS 曾经把同一个论文文件收录了两次。第二次收录顺利完成，还建立了 20 条新的知识联系。直到系统比较文件“指纹”，才确认它们完全相同。

如果只是聊天机器人偶尔答错一句话，对话结束后，错误可能也随之消失。但当 Agent 开始管理知识库，情况不同了：它不只回答，还会整理、分类、连接，并把结果保存下来。

这就带来了本文要讨论的问题：知识漂移。

错误一旦被保存，就有了以后

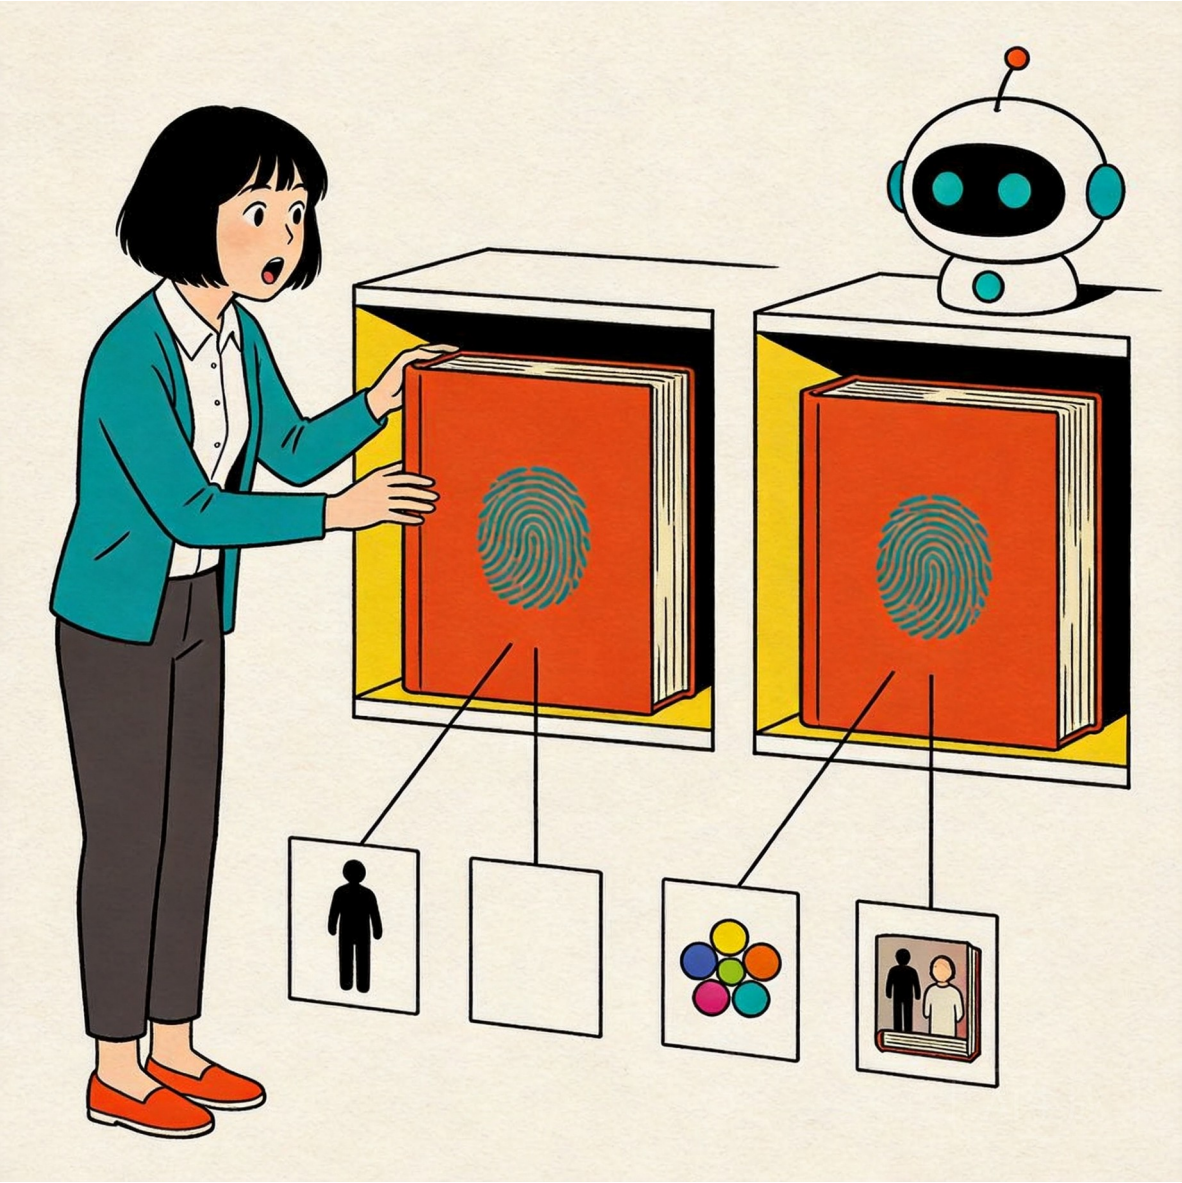
知识漂移，是知识库在不断更新时，没有人明确决定改变原意，内容或关系却慢慢偏离了原始材料。

它和正常更新并不相同。发现了新证据，经过核对后修正旧结论，这是知识在进步。漂移则更像传话：第一遍只少了一个条件，第二遍把语气说得更肯定，第三遍又把这句话当成可靠事实。

过去，知识库主要保存人输入的内容。错误通常停在某条记录里。Agent 则会把一次处理结果交给下一次任务：

> 原文被整理成摘要，摘要被用来分类，分类决定以后从哪里检索，检索结果又成为下一次写作的材料。

于是，一个小偏差不再只是过去发生的错误。它会改变系统以后看到什么、相信什么、继续写下什么。



同一份材料拥有两个身份，也会长出两套知识联系

每一步都成功，为什么结果还会偏？

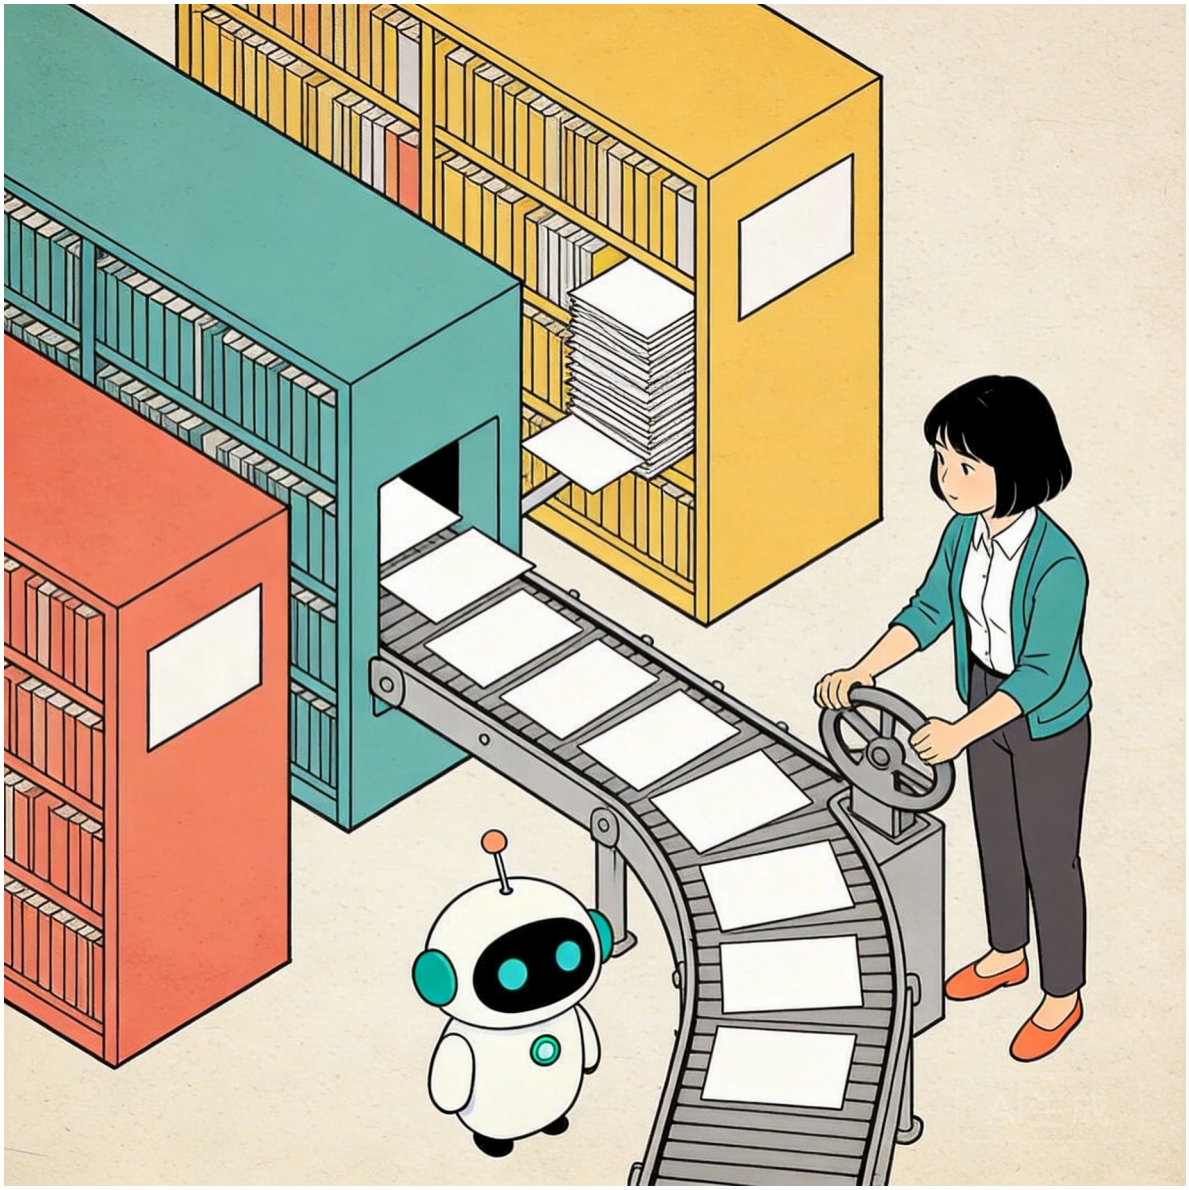
ASKS 还遇到过另一个很典型的问题。

系统新建了两个研究分类，却漏掉了帮助自动整理程序认识它们的关键信息。分类本身存在，但自动整理程序“看不见”。新论文到来时，系统只好把它们放进几个看起来相近的旧分类。

一次归错似乎不严重。可是同样的规则会反复运行。最终，前三批共有 29 篇论文需要重新归类。

这件事最值得注意的地方，是系统并没有停机。每篇论文都保存成功，每次选择也并非毫无道理。错误藏在一连串“看起来都成功”的操作中，慢慢变成了知识地图的一部分。

这正是漂移难以发现的原因：明显的胡说容易引起警觉，连续出现的合理小偏差却可能彼此证明。某个错误关系被用得越多，看起来反而越像系统早已确认的事实。



正确位置一旦不可见，合理的小偏差就会被不断重复

同样的材料，也可能长出不同的地图

知识漂移还有更隐蔽的一面：有时并不存在一条明显的错误，知识的组织方式仍会受到历史过程影响。

ASKS 后来做过一组内部重放测试。系统使用完全相同的 56 篇论文、相同的解释结果和相同的整理规则，只调整同一年论文进入知识库的先后顺序。

不同顺序最终形成了 18 到 21 个研究分组。一些底层统计很接近，具体分组和成员却明显不同。

这不等于系统答错了。它说明知识地图并非早已藏在材料里，等着机器原样取出。Agent 每加入一份材料，都是在已有地图上继续整理。先前形成的结构，会影响后来看到的结构。

因此，知识库里的原始材料和知识地图不能被当成同一件事。地图帮助我们寻找道路，却不能代替它所依据的土地。

治理漂移，先给知识留一条回去的路

ASKS 对漂移的治理，可以概括成一句话：不要求系统永不出错，而要让错误可发现、可追溯、可撤销。

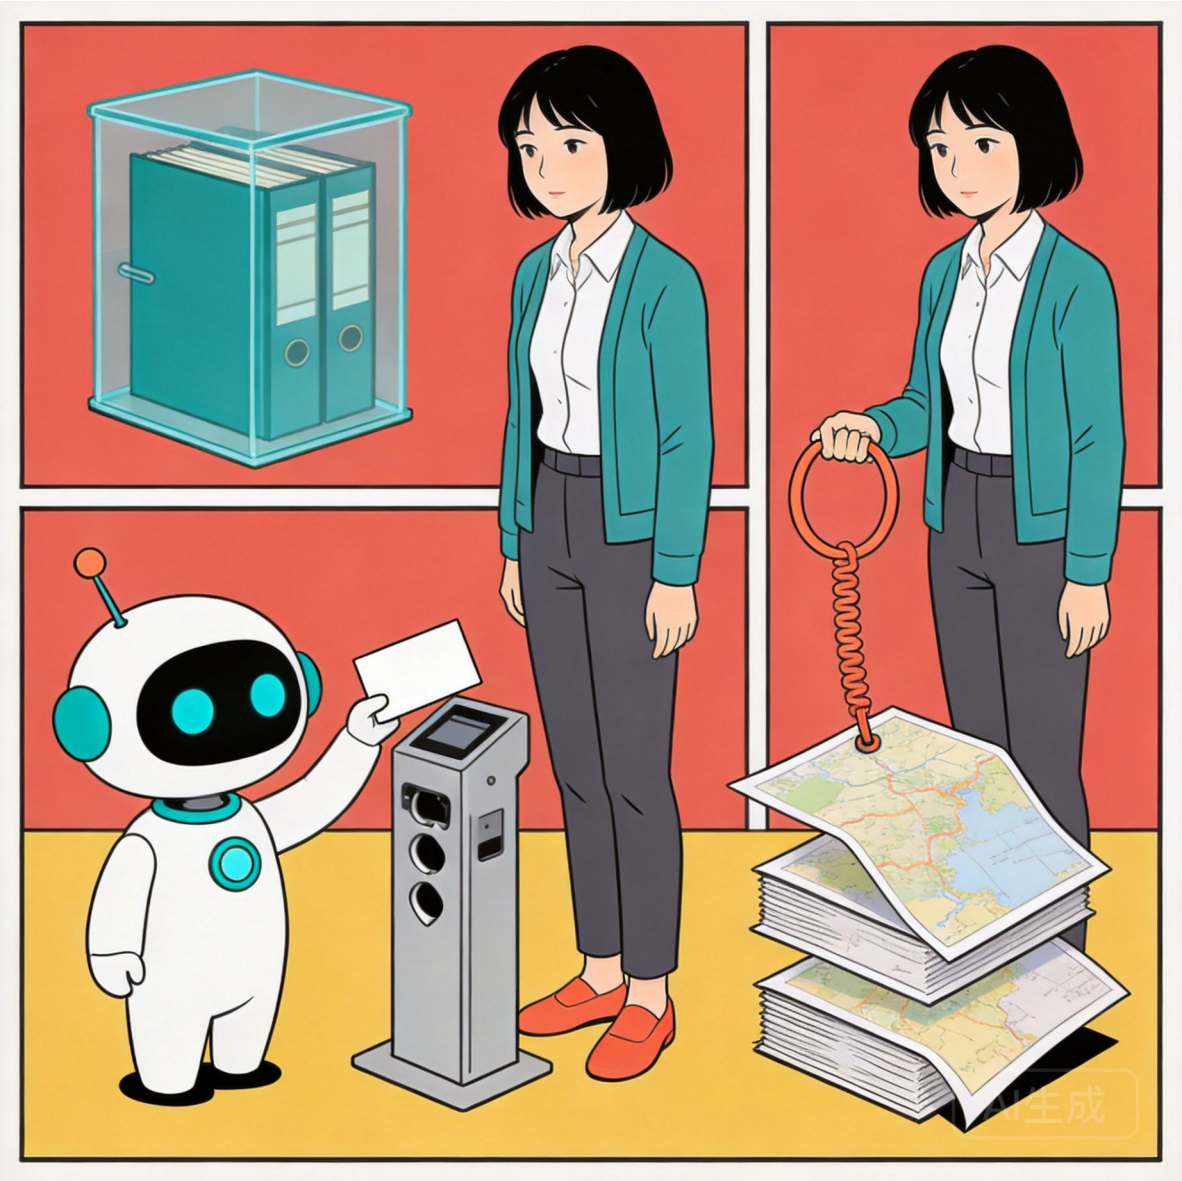
原始材料要保留。摘要写得再流畅，也不能取代论文、文件和会议记录本身。

每条重要结论和关系要记住来路。发现异常时，能够沿着记录回到它所依据的原文。

ASKS 还把一部分防漂移工作交给普通代码。代码不负责判断一篇论文讲得对不对，却能像入库闸机一样检查：这条新知识有没有原文可找、关系是否完整、是不是重复登记。一批修改只要有关键问题，就整批退回，不留下半套结果。

代码能拦住规则明确的错误，却不能判断摘要是否曲解了原文，也不能独自决定两个相似概念是不是同一个。这些判断仍需要 Agent 结合上下文处理；涉及合并身份、改变重要分类等高风险情况，还要停下来交给人确认。

那篇被重复收录的论文，最终正是这样治理的：系统用文件指纹确认重复，合并两个身份，清理多余关系，同时保留原始文件和可恢复记录。



保留原始材料、检查写入并允许撤回，才能为知识留下回去的路

要检查的不只是这次回答

面对普通问答 AI，我们习惯问：“它这次说得对吗？”

面对能够长期行动的 Agent，还要多问一句：“它把什么留给了下一次？”

这就是本篇希望读者记住的一点：

> Agent 管理知识库时，真正危险的不只是一次出错，而是偏差被写入长期记忆，并开始影响以后的行动。

当 AI 开始替我们积累知识，管理错误的生命周期，就和获得答案本身一样重要。

ASKS arXiv 论文

- Shi-Ju Ran, Kun Zhang, Xi Wu, Liu-Si Yang, and Wen-Jun Li. LLMs Interpret, Embeddings Organize, Graphs Emerge: Agent-Driven Compilation of Scientific Knowledge. arXiv preprint, arXiv:2608.29612 (2026). ASKS 的系统论文，介绍来源保留、持续知识编译和可重放更新。

相关论文推荐

- Jie Ouyang, Tingyue Pan, Mingyue Cheng, Ruiran Yan, Yucong Luo, Jiaying Lin, and Qi Liu. HoH: A Dynamic Benchmark for Evaluating the Impact of Outdated Information on Retrieval-Augmented Generation. Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pp. 6036-6063 (2025). 用大规模实验说明知识库里的过时材料怎样让 AI 产生自信但错误的回答。
- Ruotong Pan, Boxi Cao, Hongyu Lin, Xianpei Han, Jia Zheng, Sirui Wang, Xunliang Cai, and Le Sun. Not All Contexts Are Equal: Teaching LLMs Credibility-aware Generation. Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing, pp. 19844-19863 (2024). 讨论 AI 如何区别对待可信、过时或错误的外部材料，为漂移治理提供另一种思路。